

Atividade I – Machine Learning

Introdução:

Este relatório apresenta o desenvolvimento de um projeto de aprendizagem de máquina supervisionada aplicado à campanha de telemarketing de um banco português. O problema consiste em prever se um cliente aderirá a um depósito a prazo, produto semelhante a um CDB com vencimento definido. A previsão deve apoiar a priorização dos contatos com maior potencial de conversão, antes da realização das ligações.



A base Bank Marketing reúne 41.188 registros e 21 colunas referentes a características dos clientes, condições de crédito, contatos realizados, histórico de campanhas e indicadores macroeconômicos do período de 2008 a 2010. A variável-alvo, denominada *aderiu*, possui duas classes: *sim*, quando ocorreu contratação, e *nao*, quando não houve adesão. A classe positiva corresponde a aproximadamente 11,27% dos registros, o que caracteriza forte desbalanceamento.

O objetivo foi preparar os dados, treinar os classificadores k-vizinhos mais próximos, Naive Bayes e regressão logística, selecionar hiperparâmetros por validação cruzada e comparar dois cenários. O cenário principal considera apenas os atributos aceitos pela dupla para a decisão de contato, enquanto o cenário completo utiliza todas as variáveis para fins comparativos. O F1 da classe *sim* foi adotado como critério formal, com atenção adicional ao recall, pois os falsos negativos representam potenciais clientes não identificados.

Os resultados indicaram o GaussianNB como o modelo mais adequado no cenário principal. O classificador alcançou F1 de 0,3047 e recall de 0,7895 para a classe *sim*, identificando 1.099 dos 1.392 aderentes do conjunto de teste. Esse desempenho ocorreu à custa de baixa precisão e elevado número de falsos positivos, aspecto relevante para a capacidade operacional do banco.

Análise exploratória:

A inspeção inicial confirmou 41.188 linhas, ausência de valores nulos e 12 ocorrências duplicadas. A variável-alvo apresentou 36.548 registros *nao* e 4.640 registros *sim*. Também foram encontrados valores desconhecido em variáveis categóricas e o valor especial 999 em *dias_desde_ultimo_contato*, utilizado para representar clientes nunca contatados anteriormente.



Figuras 1 e 2 Número de empregados e estado civil em relação à adesão




Figura 3 Situação de inadimplência em relação à adesão

O número de empregados apresentou distribuição inferior entre os clientes aderentes, evidenciando associação entre o contexto econômico e o resultado da campanha. No estado civil, os solteiros tiveram taxa de adesão próxima de 14,0%, superior às taxas observadas entre casados e divorciados, ambas próximas de 10%. Na inadimplência, a categoria nao apresentou taxa de adesão de aproximadamente 12,9%, enquanto desconhecido apresentou cerca de 5,2%. A categoria sim contém somente três registros após a remoção das duplicatas e não permite conclusão generalizável.

Preparação dos dados:

As 12 duplicatas exatas foram removidas, resultando em 41.176 registros. Os valores desconhecido foram mantidos como categorias próprias, pois sua substituição por categorias inferidas poderia introduzir informação artificial. Embora não existissem valores nulos, imputadores foram incluídos nos pipelines como proteção para dados futuros: mediana para atributos numéricos e moda para categóricos.

O valor 999 em dias_desde_ultimo_contato não representa uma quantidade real de dias. Foi criada a variável contatado_anteriormente, com sim para clientes previamente contatados e nao para os demais. Em seguida, o valor 999 foi substituído por zero na variável de dias. Essa combinação diferencia um cliente nunca contatado de outro contatado no mesmo dia, sem manter um valor artificialmente distante.

A variável-alvo foi separada dos preditores e os dados foram divididos em 70% para treino e 30% para teste, com estratificação e random_state igual a 42. A mesma divisão foi preservada nos dois cenários. As variáveis numéricas foram padronizadas com StandardScaler, e as categóricas foram convertidas com OneHotEncoder, configurado para ignorar categorias desconhecidas. Todas as transformações foram encapsuladas em pipelines, de modo que os parâmetros de preparação fossem aprendidos somente no conjunto de treino.

Modelagem:

Os hiperparâmetros foram avaliados por validação cruzada estratificada com cinco partições, embaralhamento e random_state igual a 42. Foram calculados recall, precisão e F1 da classe sim. O F1 médio orientou a seleção, e o recall foi usado para avaliar a capacidade de reduzir oportunidades perdidas.

Modelo	Configurações avaliadas	Configuração final	Critério
k-NN	k ímpares de 1 a 43	k igual a 7	Maior F1 médio com precisão superior a 60%
Naive Bayes	GaussianNB e BernoulliNB	GaussianNB	F1 médio de 0,4526 contra 0,4408
Regressão logística	C entre 0,0001 e 1000	C igual a 1000	Maior F1 médio na busca realizada

O GaussianNB foi selecionado porque preservou a magnitude dos atributos numéricos e apresentou maior F1 médio que o BernoulliNB. A variante de Bernoulli é adequada às colunas binárias produzidas pelo one-hot, mas reduz os atributos numéricos padronizados a valores binários. O C igual a 1000 obteve o maior F1 médio na regressão logística, embora os resultados tenham se estabilizado a partir de C igual a 1, o que indica ganho marginal e regularização fraca na configuração escolhida.

Modelagem dos cenários e coeficientes:

No cenário principal, a dupla adotou uma definição conservadora e manteve apenas atributos cadastrais e macroeconômicos. Foram excluídos meio de contato, mês, dia da semana, duração da ligação, contatos na campanha atual, dias desde o último contato, contatos anteriores, resultado da campanha anterior e a variável derivada `contatado_anteriormente`. A decisão evita que o modelo dependa de histórico ou de informações operacionais de contato. O cenário completo preservou todos os atributos, inclusive a duração, que somente é conhecida após a ligação e pode elevar artificialmente a avaliação para o uso proposto.

Na regressão logística, os coeficientes representam alterações no logaritmo das chances de adesão, mantendo os demais atributos constantes. Como as variáveis numéricas foram padronizadas, cada coeficiente numérico se refere ao aumento de um desvio-padrão. Os coeficientes indicam associações aprendidas pelo modelo e não relações causais.

Atributo	Coeficiente	Interpretação
<code>taxa_variacao_emprego</code>	-2,8205	Associação negativa com as chances de adesão
<code>mes_mar</code>	1,7201	Associação positiva; não há categoria de referência omitida
<code>duracao_ligacao_seg</code>	1,2410	Associação positiva, mas indisponível antes da ligação
<code>indice_precos_consumidor</code>	1,2199	Associação positiva condicionada aos demais atributos
<code>euribor_3m</code>	0,9011	Associação positiva condicionada aos demais atributos

A taxa de variação do emprego apresentou o maior coeficiente absoluto e sinal negativo. Março apresentou associação positiva, mas sua interpretação não ocorre contra uma categoria de referência, pois o `OneHotEncoder` manteve todas as categorias. A duração da ligação também apresentou associação positiva e confirmou seu forte poder preditivo; contudo, sua indisponibilidade antes do contato impede seu uso para priorização. A interpretação dos indicadores macroeconômicos requer cautela porque esses atributos são correlacionados e descrevem o mesmo contexto econômico.

Resultados:

A Tabela 1 consolida as métricas no conjunto de teste. Para o cenário principal, também são apresentados a média e o desvio-padrão do F1 da classe sim na validação cruzada. As abreviações P, R e F1 indicam precisão, recall e F1 de cada classe.

Cenário	Modelo	Acurácia	P nao	R nao	F1 nao	P sim	R sim	F1 sim	FP	FN	F1 CV
Principal	k-NN	0,8852	0,9056	0,9719	0,9376	0,4780	0,2026	0,2846	308	1.110	$0,2851 \pm 0,0083$
Principal	GaussianNB	0,5939	0,9551	0,5691	0,7132	0,1888	0,7895	0,3047	4.723	293	$0,2989 \pm 0,0105$
Principal	Regressão logística	0,8878	0,8961	0,9881	0,9399	0,5113	0,0977	0,1641	130	1.256	$0,1706 \pm 0,0233$
Completo	k-NN	0,9007	0,9260	0,9651	0,9452	0,5888	0,3930	0,4713	382	845	-
Completo	GaussianNB	0,8479	0,9430	0,8819	0,9114	0,3842	0,5805	0,4624	1.295	584	-
Completo	Regressão logística	0,9090	0,9295	0,9712	0,9499	0,6489	0,4195	0,5096	316	808	-

Tabela 1 Comparação dos modelos nos dois cenários

No cenário principal, o GaussianNB obteve o maior F1 da classe sim, com 0,3047, e o maior recall, com 0,7895. O modelo identificou 1.099 dos 1.392 aderentes e deixou de identificar 293. Em contrapartida, registrou 4.723 falsos positivos e precisão de 0,1888. O k-NN apresentou F1 de 0,2846 e perdeu 1.110 aderentes. A regressão logística teve a maior precisão entre os modelos principais, 0,5113, mas recall de apenas 0,0977 e 1.256 falsos negativos.

Os valores de teste ficaram próximos às médias de validação cruzada. O k-NN e o GaussianNB apresentaram desvios de 0,0083 e 0,0105, respectivamente, enquanto a regressão logística mostrou maior variação, de 0,0233. A proximidade entre teste e validação indica comportamento consistente nas partições avaliadas.

Matrizes de confusão e análise dos erros:




Figura 4 Matrizes de confusão dos modelos nos cenários principal e completo

O falso negativo representa um cliente classificado como nao que efetivamente aderiria e custa uma oportunidade de captação. O falso positivo representa uma ligação a um cliente que não adere, com consumo de tempo do operador. O GaussianNB principal minimizou falsos negativos, mas exigiria capacidade para muitos contatos sem conversão.

No cenário completo, o F1 passou de 0,1641 para 0,5096 na regressão logística, de 0,2846 para 0,4713 no k-NN e de 0,3047 para 0,4624 no GaussianNB. Neste último, a precisão aumentou, mas o recall caiu de 0,7895 para 0,5805. O ganho global não torna o cenário completo automaticamente utilizável, pois ele depende de atributos excluídos da condição operacional principal, inclusive a duração da ligação.

Discussão e conclusão:

O GaussianNB foi considerado o modelo mais adequado para o cenário principal porque apresentou o maior F1 da classe sim e reduziu substancialmente os falsos negativos. Seu recall de 0,7895 está alinhado ao objetivo de identificar clientes com potencial de adesão. A escolha, entretanto, implica baixa precisão e 4.723 falsos positivos, de modo que sua aplicação depende do custo de uma ligação e da capacidade disponível de operadores.

A comparação entre cenários mostrou que a disponibilidade de atributos de contato e histórico altera tanto o desempenho quanto o tipo de erro. A regressão logística foi o melhor modelo no cenário completo, mas parte desse ganho decorre de informações que optou-se por não utilizar na priorização. O cenário completo deve ser interpretado como referência comparativa, e não como substituto automático do cenário principal.

As principais limitações são o desbalanceamento da variável-alvo, a baixa precisão do modelo selecionado, a sensibilidade dos resultados à definição operacional dos cenários e a presença de indicadores macroeconômicos correlacionados. Além disso, a campanha ocorreu entre 2008 e 2010, período sujeito a condições econômicas específicas, o que limita a extrapolação para outros contextos.

Como aprimoramentos, poderiam ser avaliados limiares de decisão escolhidos apenas no conjunto de treino, pesos diferenciados para as classes, calibração das probabilidades, métricas de priorização como precisão e recall entre os clientes de maior probabilidade e validação temporal. Também seria necessário estimar monetariamente o custo dos falsos positivos e falsos negativos para definir a melhor relação entre conversão e volume de chamadas.

Declaração de uso de ferramentas de IA generativa:

A ferramenta de inteligência artificial generativa foi utilizada como recurso de apoio ao desenvolvimento da atividade, principalmente para verificar se as interpretações elaboradas pela equipe estavam coerentes com os resultados obtidos, compreender mensagens de erro no código e esclarecer as etapas exigidas em cada item. No item 4.1, seu uso auxiliou na escolha e na elaboração das visualizações destinadas à análise da relação entre variáveis qualitativas, especificamente nos gráficos 2 e 3. No item 4.2, a ferramenta foi empregada para esclarecer os procedimentos necessários à conclusão da etapa, apresentar a função `np.where`, até então desconhecida pela equipe, interpretar as estatísticas descritivas e identificar diferenças relevantes de escala entre as variáveis. Também foi utilizada para solucionar dúvidas pontuais relacionadas ao código e à escolha de gráficos adequados para analisar relações entre variáveis qualitativas.

No item 4.3, a IA generativa auxiliou na pesquisa e na compreensão das variantes GaussianNB e BernoulliNB do algoritmo Naïve Bayes, bem como na elaboração da validação cruzada utilizada para compará-las. A ferramenta também apoiou a interpretação da média e do desvio-padrão das métricas, de modo a compreender os critérios que tornariam uma variante mais adequada do que a outra. No desenvolvimento da regressão logística, foram fornecidas orientações para testar diferentes valores do parâmetro de regularização C, adaptar a função de montagem dos modelos e construir a estrutura de repetição utilizada na busca do valor mais apropriado. Além disso, a ferramenta auxiliou na elaboração do código destinado à obtenção dos cinco coeficientes de maior magnitude e na interpretação de seus sinais e valores. Para o KNN, também houve apoio na escolha da métrica de validação cruzada, na configuração do recall para a classe positiva sim, na compreensão do erro relacionado ao parâmetro scoring e na avaliação do número de vizinhos. A escolha de $(k=7)$ foi discutida considerando conjuntamente recall, precisão, F1 e estabilidade entre as partições da validação cruzada.

No item 4.4, a ferramenta foi utilizada para discutir quais informações poderiam ser consideradas disponíveis antes do contato com o cliente e como essas variáveis poderiam auxiliar a

decisão do banco. Também houve apoio na construção dos cenários principal e completo, na separação dos conjuntos de treino e teste e na preparação dos dados de cada cenário. As variáveis históricas e de contato foram discutidas com a equipe, que decidiu manter a definição adotada no notebook com base em sua própria interpretação do problema. Ao final dessa etapa, a IA foi utilizada para verificar se as conclusões sobre a comparação entre os cenários estavam de acordo com os resultados encontrados.

Na etapa de avaliação final, a ferramenta auxiliou na organização e na interpretação das métricas dos modelos, incluindo F1, recall, precisão, acurácia, média e desvio-padrão da validação cruzada. Também contribuiu para a leitura das matrizes de confusão, para a quantificação dos falsos positivos e falsos negativos e para a discussão de seus impactos no contexto do banco. Houve ainda apoio na identificação do modelo mais adequado no cenário principal, na comparação de seu desempenho com o cenário completo e na análise sobre a viabilidade de empregar informações que não estariam disponíveis no momento real da decisão.

Por fim, a inteligência artificial generativa foi utilizada para revisar a coerência entre as solicitações da atividade, o código desenvolvido no notebook e as interpretações apresentadas, além de auxiliar na organização e na redação do relatório técnico. Isso incluiu a estruturação das seções, a síntese dos resultados, a elaboração da discussão e da conclusão e a adequação do texto à norma culta da língua portuguesa e à escrita em terceira pessoa. As sugestões fornecidas foram analisadas criticamente pela equipe, que permaneceu responsável pelas decisões metodológicas, pela execução do código, pela conferência dos resultados e pela versão final entregue.